

Self-Adaptive Multi-objective Optimization Method Design Based on Agent Reinforcement Learning for Elevator Group Control Systems

Fanlin Zeng, Qun Zong, Zhengya Sun and Liqian Dou

College of Electric and Automation Engineering, Tianjin University, Tianjin China

Abstract— This paper study the multi-objective optimization problem of elevator group control systems by using the Markov Decision Process model. Define the Agent to be the leaner and decision-maker of the MDP model. And then using reinforcement learning Algorithm combined with generic method defines the elements of this model. Moreover we use SARSA(λ) value iteration algorithm which was selected to iterative estimation the utility function combined with tile coding function approximation to design an optimization algorithm, and then prove that the solution of this algorithm will converges to a bounded domain which is given in this paper. The effect for dynamic optimization objective function of proposed approach was validated by virtual simulation environment of elevator group control systems.

Keywords—elevator group control systems, adaptive multi-objective optimization, optimizing parameters of the evaluation function, reinforcement learning, Agent, SARSA(λ) Algorithm

基于 Agent 的强化学习电梯群控自适应 多目标优化方法设计

曾凡琳 宗群 孙正雅 窦立谦

天津大学电气与自动化工程学院, 天津, 中国

摘 要 文章将电梯群控系统多目标优化问题至于马尔可夫决策过程模型下进行研究。定义了智能体作为模型中的学习和决策者, 采用强化学习算法, 结合泛化方法详细设计并定义了模型中各要素。选择收敛速度快的 SARSA(λ)值迭代算法对效用函数进行迭代估计, 给出了结合 Tile coding 函数逼近方法后的具体优化算法过程, 并证明了该算法的解收敛于有界域内, 同时给出了有界域的范围。最后, 利用电梯群控虚拟仿真环境在不同交通流模式验证了该算法的动态优化目标函数效果, 证明了算法的有效性。

关键词 电梯群控系统, 自适应多目标优化, 评价函数参数优化, 强化学习, 智能体, SARSA(λ)算法

1. 引言

电梯群控系统^[1](Elevator Group Control System, EGCS)是指将安装在建筑物内的三台或三台以上的一组电梯作为有机整体, 使用一个自动控制系统调度每一台电梯运行, 以提高系统服务质量。电梯群控系统性能具有多目标性, 且总体目标随环境改变, 需根据实际环境状况利用多目标优化算法完成电梯群控调度。故引入评价函数来衡量电梯服务性能, 选择具有最小评价函数值的电梯响应外呼。

中国国家自然科学基金项目支持(资助号: 60874073); 天津市自然科学基金项目支持(资助号: 08JCYBJC11900); 天津市科技计划项目支持(资助号: 08ZCKFGX02900); 天津市支撑课题项目支持(资助号: 08ZCKFJC27900)

在现有的电梯群控调度算法中, 静态分区算法在实际电梯系统中被广泛使用^[1], 但是该算法中每台电梯只服务特定区域, 对于乘客达到楼层相对较为分散的情况会造成电梯忙闲不均, 使得乘客候梯时间和服务时间较长。基于遗传算法的调度方法^[2]将每个染色体对应当前外呼信号, 通过完成遗传操作实现对调度策略空间的有效搜索, 但较高的乘客到达率会使该算法表现出极强的不适用性。基于多智能体的调度方法^[3]将每台电梯作为一个智能体, 各智能体之间通过相互协作来完成外呼信号响应。虽然每台电梯服务的乘客相对较为均衡, 但各项性能指标均不是最佳。为了根据环境的变化动态优化评价函数参数, N. Imasaki^[4]基于神经网络提出了一种具有学习能力的参数调整方法, Hu CF^[5]提出了一种基于模糊推理的多目标优化算法, 模糊

推理对于交通环境的短期变化具有鲁棒性,而神经网络的学习能力对于交通环境的长期变化具有适应性。于是, N. Imasaki^[6]等两种方法结合,提出一种基于模糊神经网络的参数调整方法。然而这些方法中对于评价函数参数的确定仍然依赖专家经验,同时由于缺少系统反馈信息,故不能在线自适应调整参数,无法满足时变环境需求。

基于以上考虑,本文将基于智能体的强化学习算法用于电梯群控多目标优化问题的求解以改善电梯群控调度性能。蒋国飞^[7]等利用强化学习对倒立摆进行控制; Martyna^[8]在无线智能 ATM 网络中应用强化学习解决带宽分配和拥塞避免。本文为强化学习算法定义具有自主性等特征的智能体(Agent)为计算实体,作为优化过程的学习者和决策者,并为其定义了严格的属性,让其在电梯群控问题框架下按照强化学习思路具有学习能力和决策能力,并随时接受环境影响。本文同时采用“泛化”技术简化了 Agent 对于系统状态空间的描述和搜索,使其易于在仿真过程中不断对自身进行调整。

本文首先定义电梯群控系统多目标优化模型,并将其评价函数参数优化问题至于马尔可夫决策过程(Markov decision process, MDP)模型下进行研究。定义了 Agent 作为问题模型中的学习和决策者。采用强化学习算法结合泛化方法设计了模型中各要素。其次,选择值迭代算法对算法中的效用函数进行迭代估计,给出了具体设计步骤和算法收敛性证明。最后,利用电梯群控虚拟仿真环境对该算法进行了仿真验证。

2. 电梯群控系统自适应多目标优化模型

电梯群控系统自适应多目标优化评价函数为:

$$F(i, k) = \omega_1 \frac{f_w(i, k)}{f_w^*} + \omega_2 \frac{f_s(i, k)}{f_s^*} + \omega_3 \frac{f_c(i, k)}{f_c^*} \quad (1)$$

其中, $f_w(i, k)$, $f_s(i, k)$ 和 $f_c(i, k)$ 分别为电梯 k 响应第 i 层外呼信号时所估计的乘客候梯时间的目标函数, 所需启停次数的目标函数, 轿厢内拥挤度的目标函数; f_w^* , f_s^* 和 f_c^* 分别表示期望候梯时间、启停次数、拥挤度。 $\omega_i (i=1, 2, 3)$ 为评价函数参数, $0 \leq \omega_i \leq 1$ 且 $\omega_1 + \omega_2 + \omega_3 = 1$ 。

以马尔可夫决策过程作为模型, 研究电梯群控系统自适应多目标优化问题中评价函数调节单元的参数 ω_i 优化问题, 即以时间触发机制学习和更新评价函数参数。MDP 模型由四元组 $\langle S, A, R, P \rangle$ 定义。其中, S 代表有限状态集合, 大小为 $|S| = m$; A 代表有限动作集合, 大小为 $|A| = n$; $R: S \times A \rightarrow \mathbb{R}$ (实数域) 代表报酬函数, $P: S \times A \rightarrow PD(S)$: 代表状态转移函数, PD 为状态集 S 上的一个概率分布函数。定义具有自主性、社会性、反应性、主动性等特征的计算实体智能体 Agent 作为学习者和决策者, 完成电梯群控优化过程, 作为模型中的优化算法主体, 它将具有感知

外界环境信息、自主学习、自主寻优、主动决策等能力。在电梯群控自适应多目标优化系统中, MDP 模型中各要素分别定义如下。

(1) **状态集**: 评价参数 ω_i 的大小, 即状态信息 $s \in S$ 。

(2) **动作集**: 评价函数参数的调整方向即为决策动作 $a \in A$ 。作为决策主体的 Agnet, 其决策动作离散为 $A = \{a_0, a_1, \dots, a_8\}$ 九个方向, 如图 1 所示。在每个学习时间步, Agent 从九个方向中依据策略选择一个合适的方向移动固定的步长。




图 1 评价函数调节单元的状态、动作示意图

(3) **策略集**: 为 Agent 定义随机策略 $\pi: S \rightarrow \Omega(A)$ 为从状态到动作的概率分布映射^[9], 其中 $\Omega(A)$ 为在动作 A 上的所有概率分布的集合。让 Agent 以一定概率随机地选择动作, 然后逐渐产生高报酬动作。Agnet 采用 ϵ -贪婪策略进行策略学习, t 时刻对状态 s 以概率 $\epsilon_t(s)$ 随机地选择动作, 而以概率 $1 - \epsilon_t(s)$ 选择对应于最大 Q 值的动作。如果对于任意的状态-动作对 (s, a) 的随机策略 $\pi(s, a) \geq \epsilon, \epsilon \in (0, 1]$ 则称策略 π 为 ϵ -soft, 定义为 π_ϵ 。

(4) **报酬集**: 在电梯群控系统优化环境模型中需要 Agent 依赖环境所赋予的立即报酬学习策略。故定义:

$$J = J_w(i, k) + J_s(i, k) + J_c(i, k) \quad (2)$$

其中, $J_w(i, k)$ 、 $J_s(i, k)$ 及 $J_c(i, k)$ 分别为电梯 k 响应第 i 层外呼信号时乘客候梯时间、电梯启停次数以及轿厢内拥挤度的惩罚函数。采用 β 表示可接受目标的最小优化程度, 当 $J \leq \beta$ 时接受优化解, 令立即报酬 $r = 0$; 否则, 调整参数, 令立即报酬 $r = -J$ 。Agent 在 t 时刻产生的累计报酬为 R_t :

$$R_t = E \left(\sum_{i=1}^{\infty} \gamma^i r_{t+i} = r_{t+1} + \gamma R_{t+1} \right), 0 < \gamma \leq 1 \quad (3)$$

其中, r_{t+i} 表示 $t+i$ 时刻 Agent 遵循策略 π 所获得的立即报酬; γ 表示折扣因子, $\gamma \in [0, 1)$ 。此外, 定义 $\bar{R}_\pi \in \mathbb{R}^m$ 表示遵循随机策略 π , 系统的立即报酬向量。

(5) **状态转移矩阵**: 定义 $P_\pi \in \mathbb{R}^{m \times m}$ 表示遵循随机策略 π , 系统状态-动作对的转移概率矩阵。在任何随机策略 π 下, 假设马尔可夫决策过程在状态集合上是不可约、非周期马

尔可夫链，那么对于 $\forall \pi$ ， P_π 具有唯一的平稳分布 $\bar{\mu}_\pi \in \mathfrak{R}^{mn}$ ，并且 $\bar{\mu}_\pi$ 的所有元素和为 1。定义 $D_\pi \in \mathfrak{R}^{mn \times mn}$ ，并且 $D_\pi = \text{diag}(\bar{\mu}_\pi)$ 。

(6)效用函数：在策略和立即报酬之间定义以状态 s 为自变量的值函数 $V^\pi(s)$ （即状态效用函数）：

$$V^\pi(s) = E_\pi \{ r_{t+1} + \gamma V^\pi(s_{t+1}) | s_t = s \} \quad (4)$$

进而定义以状态—动作对 (s, a) 为自变量的动作值函数 $Q^\pi(s, a)$ （即状态—动作对效用函数）用于策略选择：

$$Q^\pi(s, a) = E_\pi [r_{t+1}(s, a) + \gamma V^\pi(s_{t+1}) | s_t = s] \quad (5)$$

强化学习的目标即通过最优动作值函数获取最优策略，研究与环境进行交互的 Agent 如何学习行为策略 π ，以最大化系统 t 时刻的累计报酬 R_t 。

(7)效用函数泛化：在求解过程中引入动作值函数的 Tile coding 泛化作为逼近器，使得 Agent 具有把学习到的知识紧缩存储的能力。以状态 s 和动作 a 的函数特征向量 $\bar{\phi}_{sa} \in \mathfrak{R}^k$ 表示并作为 Tile coding 的输入，以动作值函数作为其输出。Tile coding 的结构设计为 N_L 层，表示为 Tiling i ， $i = 1 \cdots N_L$ ；第 i 层中包含 N_i 个 tile，表示为 tile j ， $j = 1 \cdots N_i$ 。如果某个 tile 包含给定状态—动作对则称其为激活 tile， $\phi_i^j = 1$ ；反之则 $\phi_i^j = 0$ 。Tile coding 的输出映射为：

$$f(\bar{\phi}_{sa}, \bar{w}) = \sum_{i=1}^{N_L} \sum_{j=1}^{N_i} \phi_i^j(s, a) w_i^j \quad (6)$$

其中， $\bar{w} \in \mathfrak{R}^k$ 为权值向量。则 Tile coding 输出近似动作值函数为 $\hat{Q}(s, a) = \bar{\phi}_{sa}^T \bar{w}$ 。定义 Φ 为 $mn \times k$ 矩阵，行向量表示一个状态—动作对的特征向量，那么近似动作值函数矩阵 $\bar{Q} = \Phi \bar{w}$ ，其中 $\bar{Q} \in \mathfrak{R}^{mn}$ ，这里假设 Φ 的列向量线性无关。取 $\langle (s_t, a_t), Q_{t+1}(s_t, a_t) \rangle$ 为 Tile coding 的训练样本， s_t, a_t 分别为 t 时刻所处的实际状态和执行动作，更新规则为：

$$w \leftarrow w + \frac{\alpha}{N_L} (r + \gamma Q_t(s_{t+1}, a_{t+1}) - Q_t(s_t, a_t)) \phi(s_t, a_t) \quad (7)$$

3. 基于智能体的强化学习自适应多目标优化算法设计

至此，电梯群控问题被转化为多目标优化问题，并采用强化学习原理进行评价函数参数优化求解。但是在实际电模型中，报酬函数和状态转移函数未知，故效用函数无法直接计算，需采用迭代方法对其进行估计。本文采用收敛速度快的 SARSA(λ)^[10] 值迭代方法进行效用函数的估计，并证明结合线性函数逼近的 SARSA(λ) 算法遵循某种学习策略，迭代产生的解收敛于有界域内，同时给出有界域的范围。

3.1 SARSA(λ) 值迭代学习算法设计

SARSA(λ) 值迭代算法的迭代公式如下^[10]：

$$Q(s, a) \leftarrow Q(s, a) + \alpha (r_{t+1}(s, a) + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)) e(s, a) \quad (8)$$

定义 TD (Temporal Difference) 误差：

$\delta = r_{t+1}(s, a) + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)$ ， $e(s, a)$ 表示状态—动作对 (s, a) 的资格迹，在学习过程中记忆所经历过的状态和所执行的动作。当 TD 误差产生时，对资格迹记忆的相关状态的值函数进行更新。资格迹的更新策略为：

$$e_{t+1}(s, a) = \begin{cases} \gamma \lambda e_t(s, a), & \text{if } (s, a) \neq (s_t, a_t) \\ 1, & \text{if } (s, a) = (s_t, a_t) \end{cases} \quad (9)$$

其中， $\gamma (0 \leq \gamma \leq 1)$ 为折扣因子， $\lambda (0 \leq \lambda \leq 1)$ 为衰减因子。定义 $T_\pi^{(\lambda)}$ 表示遵循策略 π ，采用 SARSA(λ) 更新动作值函数的迭代算子：

$$(T_\pi^{(\lambda)} Q_t) = (1 - \lambda) \sum_{i=0}^{\infty} \lambda^i \cdot E \left[\sum_{m=0}^i \gamma^m r_{t+m+1} + \gamma^{i+1} Q_{t+m+1} \right] \quad (10)$$

用 Π 表示动作值函数的线性函数逼近算子，定义算子 $H_\pi^{(\lambda)}$ ：

$$\Phi \bar{w}_{k+1} = H_\pi^{(\lambda)} \Phi \bar{w}_k \quad (11)$$

在结合了 Tile coding 函数逼近方法后，值迭代评价函数参数优化算法的简要计算过程为：

- (1)初始化：令 $t = 0$ ， $\bar{w} = 0$ ， $\bar{e} = 0$ ；
- (2)定义动作值函数： $Q_w(s, a) = \bar{\phi}_{sa}^T \bar{w}$
- (3)在时刻 t ，执行动作 a_t ，得到下一时刻的状态 s_{t+1} 以及立即报酬 r_{t+1} ；
- (4)根据随机策略 π_e 和动作值函数，选择状态为 s_{t+1} 时的评价函数参数调整方向 a_{t+1} ；
- (5)计算 TD 误差： $\delta = r_{t+1} + \gamma Q_w(s_{t+1}, a_{t+1}) - Q_w(s_t, a_t)$
- (6)如果状态—动作对 (s_t, a_t) 对应 Tiling i 中的 tile j ，根据下式更新资格迹： $\bar{e} \leftarrow \gamma \lambda \bar{e}, e_t^j(s_t, a_t) \leftarrow 1$
- (7)根据下式更新权值： $\bar{w} \leftarrow \bar{w} + \frac{\alpha}{N_L} \delta \bar{e}$
- (8)更新当前状态和动作： $s_t \leftarrow s_{t+1}, a_t \leftarrow a_{t+1}$
- (9)直到目标状态出现，则学习结束，否则令 $t = t + 1$ ，并返回(3)。

3.2 SARSA(λ) 值迭代学习算法收敛性分析

在进行收敛性分析以前，首先给出基本数学概念：对于任意向量 $\bar{x} \in \mathfrak{R}^{mn}$ ，定义 $\bar{x}$ 的范数

$$\|\bar{x}\|_{D_\pi} = (\bar{x}^T D_\pi \bar{x})^{1/2}$$

相应地，对于 $\mathfrak{R}^{mn \times mn}$ 中的任意方阵 A ，

定义 $\|A\|_{D_\pi}$ 表示由向量范数 $\|\cdot\|_{D_\pi}$ 导出的算子范数，即

$\|A\|_{D_\pi} = \max_{\|\vec{x}\|_{D_\pi}=1} \|A\vec{x}\|_{D_\pi}$; 定义 $\vec{x}$ 的范数 $\|\vec{x}\|$ 为欧几里德范数, 相应地, 定义 $\|A\|$ 表示由向量范数 $\|\vec{x}\|$ 导出的算子范数, 即

$$\|A\| = \max_{\|\vec{x}\|=1} \|A\vec{x}\|.$$

引理 1^[11] 平稳分布 $\bar{\mu}_\pi$ 是关于策略 π 的连续分布。

引理 2 D_π 是关于策略 π 的连续分布。

由于 $D_\pi = \text{diag}(\bar{\mu}_\pi)$, 因此该引理容易得证。

引理 3 对于任意策略 π , 方程 $\Phi \bar{w}_\pi = H_\pi^{(\lambda)} \Phi \bar{w}_\pi$ 的唯一解 $\bar{w}_\pi$ 是关于 π 的连续函数。

证明: 由方程 $\Phi \bar{w}_\pi = H_\pi^{(\lambda)} \Phi \bar{w}_\pi$ 可得:

$$\begin{aligned} & \left[I - \gamma(1-\lambda)\Pi_\pi P_\pi \sum_{t=0}^{\infty} (\gamma \lambda P_\pi)^t \right] \Phi \bar{w}_\pi \\ &= (1-\lambda)\Pi_\pi \sum_{t=0}^{\infty} \lambda^t \sum_{m=0}^{\infty} (\gamma P_\pi)^m \bar{R}_\pi \end{aligned} \quad (12)$$

已知 $\|\Pi_\pi P_\pi\|_{D_\pi} \leq 1$ ^[12], 于是,

$$\left\| \gamma(1-\lambda)\Pi_\pi P_\pi \sum_{t=0}^{\infty} (\gamma \lambda P_\pi)^t \right\|_{D_\pi} \leq \|\Pi_\pi P_\pi\|_{D_\pi} \leq 1 \quad (13)$$

所以, $\gamma(1-\lambda)\Pi_\pi P_\pi \sum_{t=0}^{\infty} (\gamma \lambda P_\pi)^t$ 的所有特征值都在单位圆内 (也可能在单位圆上), 容易得出, 矩阵 $I - \gamma(1-\lambda)\Pi_\pi P_\pi \sum_{t=0}^{\infty} (\gamma \lambda P_\pi)^t$ 是可逆的, 且矩阵 Φ 为列满秩因此, 可以将(12)式转化为:

$$\begin{aligned} \bar{w}_\pi &= (\Phi^T \Phi)^{-1} \Phi^T \left(I - \gamma(1-\lambda)\Pi_\pi P_\pi \sum_{t=0}^{\infty} (\gamma \lambda P_\pi)^t \right)^{-1} \cdot \\ & (1-\lambda)\Pi_\pi \sum_{t=0}^{\infty} \lambda^t \sum_{m=0}^{\infty} (\gamma P_\pi)^m \bar{R}_\pi \end{aligned} \quad (14)$$

由于算子 Π_π 对应于矩阵 $\Phi(\Phi^T D_\pi \Phi)^{-1} \Phi^T D_\pi$ ^[11], 该矩阵是 π 的连续函数, 因此, $\bar{w}_\pi$ 是关于 π 的连续函数。 **证毕。**

假设学习策略为 π , 定义:

$$s_\pi^{(\lambda)}(\bar{w}) = \Phi^T D_\pi (T_\pi^{(\lambda)} \Phi \bar{w} - \Phi \bar{w}) \quad (15)$$

然后, 定义函数 $F_\pi^{(\lambda)}: \mathfrak{R}^k \mapsto \mathfrak{R}^k$,

$$F_\pi^{(\lambda)}(\bar{w}) = \bar{w} + \alpha s_\pi^{(\lambda)}(\bar{w}) \quad (16)$$

假设学习策略为 π_ε :

$$\pi_\varepsilon(s, a) = \exp[Q(s, a)/\varepsilon] / \sum_{a' \in A} \exp[Q(s, a')/\varepsilon] \quad (17)$$

那么, 定义:

$$s_{\pi_\varepsilon}^{(\lambda)}(\bar{w}) = \Phi^T D_{\pi_\varepsilon} (T_{\pi_\varepsilon}^{(\lambda)} \Phi \bar{w} - \Phi \bar{w}) \quad (18)$$

然后, 定义函数 $F_{\pi_\varepsilon}^{(\lambda)}: \mathfrak{R}^k \mapsto \mathfrak{R}^k$,

$$F_{\pi_\varepsilon}^{(\lambda)}(\bar{w}) = \bar{w} + \alpha s_{\pi_\varepsilon}^{(\lambda)}(\bar{w}) \quad (19)$$

引理 4 对于 $\forall \varepsilon > 0, \alpha > 0$, 权值向量 $\bar{w}$ 是 $F_{\pi_\varepsilon}^{(\lambda)}$ (或 $F_{\pi_\varepsilon}^{(\lambda)}$) 的不动点当且仅当 $\Phi \bar{w}$ 是 $H_\pi^{(\lambda)}$ (或 $H_{\pi_\varepsilon}^{(\lambda)}$) 的不动点。

证明: 必要性。若 $\bar{w}$ 是 $F_{\pi_\varepsilon}^{(\lambda)}$ 的不动点成立, 则有

$$\begin{aligned} s_\pi^{(\lambda)} &= 0 \\ \Rightarrow \Phi^T D_\pi \sum_{t=0}^{\infty} (\gamma \lambda P_\pi)^t (\bar{R}_\pi + \gamma P_\pi \Phi \bar{w} - \Phi \bar{w}) &= 0 \\ \Rightarrow \Phi \bar{w} &= \Pi_\pi T_\pi^{(\lambda)} \Phi \bar{w} \end{aligned} \quad (20)$$

因此, $\Phi \bar{w}$ 是 $H_\pi^{(\lambda)}$ 的不动点, 采用相反的步骤即可以证得充分性。同理可证, 权值向量 $\bar{w}$ 是 $F_{\pi_\varepsilon}^{(\lambda)}$ 的不动点当且仅当 $\Phi \bar{w}$ 是 $H_{\pi_\varepsilon}^{(\lambda)}$ 的不动点。 **证毕。**

引理 5 存在常数 $\alpha^* > 0$, 使得对于 $\forall \pi$ 以及 $\alpha \in (0, \alpha^*)$, 存在标量 $\beta_\alpha \in (0, 1)$ 使得,

$$\|F_\pi^{(\lambda)}(\bar{w}) - \bar{w}_\pi\| \leq \beta_\alpha \|\bar{w} - \bar{w}_\pi\| \quad (21)$$

证明: 根据 $s_\pi^{(\lambda)}(\bar{w})$ 的定义可以推得下面的等式,

$$s_\pi^{(\lambda)}(\bar{w}) = \Phi^T D_\pi (\Pi_\pi T_\pi^{(\lambda)} \Phi \bar{w} - \Phi \bar{w}) \quad (22)$$

对于 $\forall \pi$ 已知 $\|H_\pi^{(\lambda)} \Phi \bar{w} - \Phi \bar{w}_\pi\|_{D_\pi} \leq \gamma \|\Phi \bar{w} - \Phi \bar{w}_\pi\|_{D_\pi}$ ^[13], 那么

$$\begin{aligned} & (\bar{w} - \bar{w}_\pi)^T s_\pi^{(\lambda)}(\bar{w}) \\ &= \langle \Phi \bar{w} - \Phi \bar{w}_\pi, (H_\pi^{(\lambda)} \Phi \bar{w} - \Phi \bar{w}_\pi) + (\Phi \bar{w}_\pi - \Phi \bar{w}) \rangle_{D_\pi} \\ &\leq (\gamma - 1) \|\Phi \bar{w} - \Phi \bar{w}_\pi\|_{D_\pi}^2 \\ &\leq (\gamma - 1) (\bar{w} - \bar{w}_\pi)^T (\Phi^T D_\pi \Phi) (\bar{w} - \bar{w}_\pi) \end{aligned} \quad (23)$$

由于对于 $\forall \pi$, D_π 正定, 即 $(\bar{w} - \bar{w}_\pi)^T (\Phi^T D_\pi \Phi) (\bar{w} - \bar{w}_\pi) > 0$,

于是, 存在常数 $C_1 > 0$, 使得, $(\bar{w} - \bar{w}_\pi)^T s_\pi^{(\lambda)}(\bar{w}) \leq -C_1 \|\bar{w} - \bar{w}_\pi\|^2$ (24)

而且,

$$\begin{aligned} & \|s_\pi^{(\lambda)}(\bar{w})\|^2 \\ &= \sum_{i=1}^k (\phi_i^T D_\pi (\Pi_\pi T_\pi^{(\lambda)} \Phi \bar{w} - \Phi \bar{w}))^2 \\ &\leq \sum_{i=1}^k \|\phi_i\|_{D_\pi}^2 \left(\gamma \|\Phi \bar{w} - \Phi \bar{w}_\pi\|_{D_\pi} + \|\Phi \bar{w}_\pi - \Phi \bar{w}\|_{D_\pi} \right)^2 \\ &= (1 + \gamma)^2 \sum_{i=1}^k \|\phi_i\|_{D_\pi}^2 \|\Phi \bar{w}_\pi - \Phi \bar{w}\|_{D_\pi}^2 \end{aligned}$$

于是, 存在常数 $C_2 > 0$, 使得

$$\|s_\pi^{(\lambda)}(\bar{w})\|^2 \leq C_2 \|\bar{w} - \bar{w}_\pi\|^2 \quad (25)$$

利用不等式(24)、(25), 得到:

$$\begin{aligned} & \|F_\pi^{(\lambda)}(\bar{w}) - \bar{w}_\pi\|^2 \\ &= \|\bar{w} - \bar{w}_\pi\|^2 + 2\alpha (\bar{w} - \bar{w}_\pi)^T s_\pi^{(\lambda)}(\bar{w}) + \alpha^2 \|s_\pi^{(\lambda)}(\bar{w})\|^2 \end{aligned}$$

$$\leq (1 - 2\alpha C_1 + \alpha^2 C_2) \|\bar{w} - \bar{w}_\pi\|^2$$

取 $\alpha^* = 2C_1/C_2$ ，即可证得不等式(21)。 **证毕。**

定理 对于 $\forall \alpha > 0$ 以及 $\varepsilon > 0$ ， $F_{\pi_\varepsilon}^{(\lambda)}$ 的所有不动点收敛于有界域内。

证明：由引理 3 知， $\bar{w}_\pi$ 是关于 π 的连续函数，由于 π 为紧集，所以，如果记 $R = \{\bar{w}_\pi | \pi \in [0,1]\}$ ，则该集合有界。令 $\bar{R} = \max\{\|\bar{w}\| | \bar{w} \in R\}$ 根据引理 5 知，对于 $\forall \pi$ ，设置 $\alpha > 0$ ，使得对于 $\forall \pi$ ，存在 $\beta \in (0,1)$ ，满足 $\|F_{\pi_\varepsilon}^{(\lambda)}(\bar{w}) - \bar{w}_\pi\| \leq \beta \|\bar{w} - \bar{w}_\pi\|$ 。于是，

$$\|F_{\pi_\varepsilon}^{(\lambda)}(\bar{w})\| \leq \|F_{\pi_\varepsilon}^{(\lambda)}(\bar{w}) - \bar{w}_{\pi_\varepsilon}\| + \|\bar{w}_{\pi_\varepsilon}\| \leq \beta \|\bar{w}\| + (1 + \beta)\bar{R}$$

取 $C = \{\bar{w} | \|\bar{w}\| \leq (1 + \beta)\bar{R}/(1 - \beta)\}$ ，那么 $\|F_{\pi_\varepsilon}^{(\lambda)}(\bar{w})\| \in C$ ，由于 $F_{\pi_\varepsilon}^{(\lambda)}(\bar{w})$ 是关于 $\bar{w}$ 连续函数，所以根据 Brouwer 不动点定理^[14]可以得证 $F_{\pi_\varepsilon}^{(\lambda)}$ 在有界闭域 C 内存在不动点，并且其所有不动点都在有界闭域 C 内，于是得证。 **证毕。**

由证明结果可以得出结合线性函数逼近的 SARSA(λ) 算法，当遵循学习策略 π_ε 时，权值向量 $\bar{w}$ 至少存在一个不动点，并且所有不动点都在有界域 C 内。

4. 仿真验证

利用实验室开发的电梯群控虚拟仿真环境^[15]进行算法的仿真验证。电梯群控系统自适应多目标优化结构如图 2 所示。为了实现电梯群控系统的自适应多目标优化，使评价函数参数能够适应系统当前的交通流状态，每隔时间周期 T （这里选取 5 分钟），对交通流进行一次交通流特征提取和模式识别，利用知识库中的数据确定交通流所属类别，同时在知识库中寻找与该交通流类别相匹配的评价函数参数。在周期 T 内，每隔单位时间（这里选择 1 分钟）系统获得优化过程中的各环境变量，然后与期望值作比较得出偏差，评价函数调节单元跟踪偏差调整评价函数参数，并通过评价函数计算单元得出优化结果交由控制器（调度单元）进行派梯，最后根据系统环境和各目标函数优化后的反馈信息对知识库进行更新。




图 2 电梯群控系统自适应多目标优化结构图

电梯虚拟环境模拟 4 台电梯运行于 16 层环境中，虚拟环境参数如下：门厅高度 4 米，其余楼层 3 米；电梯额定速度 2.5 米/秒；电梯加速度 1 米/秒²；电梯开关门时间 1 秒；电梯额定容量 12 人。优化算法参数分别为：折扣因子 $\gamma = 0.9$ ，动作值函数的学习速率 $\alpha = 0.6$ ，资格迹的衰减因子 $\lambda = 0.5$ ，随机策略参数的学习速率 $\eta = 0.5$ ，贪婪策略的探索因子 $\varepsilon = 0.08$ ，评价函数参数初始值为 $\omega_1 = 0.65, \omega_2 = 0.25, \omega_3 = 0.1$ 。

将评价函数参数优化方法与电梯群控虚拟仿真环境结合，实现对电梯群控系统的自适应多目标调度优化，那么在虚拟仿真环境中进行优化派梯，即可以看作是基于强化学习的评价函数参数优化方法的学习过程。利用电梯虚拟仿真环境的交通流发生器产生上高峰和下高峰两种不同的模拟交通流，用于算法训练。其中，上高峰交通模式在 10 分钟内到达 170 人，流入比例 74%，流出比例 11%，层间比例 15%。下高峰交通模式在 10 分钟内到达 170 人，流入比例 9%，流出比例 70%，层间比例 21%。在两种交通流模式下，优化算法在虚拟仿真环境下电梯实际运行结果如图 3 所示。




图 3 优化算法在虚拟仿真环境下电梯实际运行结果图

图中纵轴表示实际运行的目标函数值与期望性目标函数值的相对误差，其中实线为上高峰模式下的仿真结果，虚线为下高峰模式下的仿真结果。可以看出，在不同的交通模式下，使用优化评价函数参数来实现电梯群控系统的自适应多目标优化过程，在 330 分钟（虚拟仿真环境时间）的学习时间下，最终均可以使电梯的实际运行目标函数值达到相应的期望值。由于每一次仿真训练都是在对算法同一个泛化网络进行迭代更新，而通过对不同的交通模式进行训练会使得强化学习方法在运行过程中不断学习去适应变化的交通模式，因此在真正意义上实现了电梯群控系统的自适应多目标优化。

5. 结论

本文首先定义电梯群控系统多目标优化模型，并将其评价函数参数优化问题至于基于 Agent 的 MDP 模型下进行研究。采用强化学习算法思想，结合泛化方法详细设计并

定义了电梯群控系统多目标优化问题在 MDP 模型中的状态集、动作集、策略集、报酬集、状态转移矩阵、效用函数、效用函数泛化等七个要素。其次选择 SARSA(λ) 值迭代算法对效用函数进行迭代估计, 给出了算法过程, 并证明了其解收敛于有界域内, 同时给出了有界域的范围。最后, 利用电梯群控虚拟仿真环境对该算法进行了仿真验证。在设定大楼、电梯环境以及算法参数的基础上, 在上高峰交通模式和下高峰交通模式下, 分别重复执行两种不同的评价函数参数优化方法, 研究在动态优化目标函数的过程中, 电梯群控系统的实际目标函数值与相应期望值的逼近过程, 验证了该方法的有效性。

参考文献

- [1] R. Crites, A. Barto, "Elevator Group Control using Multiple Reinforcement Learning Agents," *Machine Learning*, 1998, 32(2), pp. 235~262.
- [2] P. Cortes, J. Larraneta, J. Larraneta, "A Genetic Algorithm for Controlling Elevator Group Systems," *Lecture Notes in Computer Science*, Springer Berlin, 2003
- [3] Qun Zong, Liqian Dou, Weijia Wang, "Elevator Group Control Scheduling Approach Based on Multi-Agent Coordination," *WCICA* 2006, 2. pp.7249~7253.
- [4] N. Imasaki, "Fuzzy Neural-Network Simulator and Its Application," *In Proceedings of Japan Industry Applications Society Conference*, 1990, S.195~S.198
- [5] Hu CF, Teng CJ, Li SY, "A fuzzy goal programming approach to multi-objective optimization problem with priorities," *European Journal of Operational Research*, 2007, 176(3), pp.1319-1333.
- [6] Naoki Imasaki et al, "Elevator Group Control System Tuned by Fuzzy Neural Network Applied Method," *International Joint Conference of the Fourth IEEE International Conference on Fuzzy Systems*, 1995, 4. pp. 1735~1740
- [7] Jiang Guo-Fei, Wu Cang-Pu, "Learning to Control an Inverted Pendulum using Q-learning and Neural Networks," *Acta Automatica Sinica*, 1998, 24(5).pp. 666~669
- [8] Martyna, "Reinforcement Learning for Control of Traffic and Access Points in Intelligent Wireless ATM Networks," *Lecture Notes in Computer Science*, 2001. pp. 554~564
- [9] Michail G. Lagoudakis, "Efficient Approximate Policy Iteration Methods For Sequential Decision Making in Reinforcement Learning," [Ph D. Dissertation]. Duke University, 2003
- [10] G. A. Rummery, "Problem Solving with Reinforcement Learning," [Ph D. Dissertation]. Cambridge University, London, England, 1995
- [11] D. P. de Farias, B. Van Roy, "On the Existence of Fixed Points for Approximate Value Iteration and Temporal Difference Learning," *Journal of Optimization Theory and Applications*, 2000, 105(3) pp.589~608
- [12] Benjamin Van Roy, "Learning and Value Function Approximation in Complex Decision Processes," [Ph D. Dissertation]. MIT, 1998
- [13] John N. Tsitsiklis, Benjamin Van Roy. An Analysis of Temporal Difference Learning with Function Approximation. *IEEE Transactions on Automatic Control*, 1997, 42(5) pp.674~690
- [14] R. B. Kellogg, T. Y. Li, J. A. Yorke, "A Constructive Proof of Brouwer Fixed-point Theorem and Computational Results," *SIAM J Numer Anal*, 1976, 13 pp. 473~483
- [15] ZONG Qun, HE Yan-zhao, WEI Li-jian, "Modeling and Research for Agent-Oriented Elevator Group Control Simulation System," *Journal of System Simulation*, 2006, 18(5). pp.1391-1393